

# Deteksi *Subsurface Hazard Anomaly* pada Data Seismik Menggunakan Pendekatan YOLO

Ahmad Naufal Ramadan - 13522005

Program Studi Teknik Informatika

Sekolah Teknik Elektro dan Informatika

Institut Teknologi Bandung

Jl. Ganesha 10 Bandung 40132, Indonesia

13522005@std.stei.itb.ac.id, naufalahmad022@gmail.com

**Abstrak**—Makalah ini menyajikan pendekatan *deep learning* untuk identifikasi otomatis *subsurface geological hazards* pada citra seismik menggunakan kerangka kerja *object detection* You Only Look Once (YOLO). *Seismic interpretation* secara tradisional merupakan proses manual yang memakan waktu dan bersifat subjektif. Kami mendemonstrasikan bahwa YOLO dapat melokalisasi anomali seperti *fault zones*, *gas chimneys*, dan *subsurface voids* dengan cepat dan akurat. Metodologi kami melibatkan alur *preprocessing* yang ketat, termasuk *percentile-based contrast normalization* dan *overlapping tiling* untuk menangani penampang seismik berskala besar. Hasil eksperimen menunjukkan bahwa model mencapai akurasi yang signifikan dalam mendeteksi pola berbahaya, menawarkan alat yang menjanjikan untuk membantu ahli geofisika dalam survei awal dan *risk assessment*.

**Kata Kunci**—*Seismic Interpretation, Subsurface Hazards, Object Detection, YOLO, Deep Learning, Geophysics, Digital Image Processing*

## I. PENDAHULUAN

*Seismic interpretation* merupakan langkah fundamental dalam eksplorasi hidrokarbon dan penilaian *subsurface hazard*. Proses ini melibatkan analisis data refleksi seismik untuk mengidentifikasi struktur geologi seperti *faults*, *horizons*, dan *gas chimneys* [1]. Secara tradisional, proses ini dilakukan secara manual oleh interpreter berpengalaman, yang memakan waktu dan bersifat subjektif, sehingga berpotensi menimbulkan inkonsistensi dalam penilaian risiko.

Seiring dengan pertumbuhan volume data seismik yang eksponensial, interpretasi manual menjadi hambatan utama (*bottleneck*). Selain itu, fitur bahaya yang halus seperti *small fault zones* atau *gas pockets* dapat dengan mudah terlewatkan dalam data yang *noisy*, yang menimbulkan risiko signifikan bagi operasi pengeboran. Metode otomatis yang ada sering kali bergantung pada teknik *image processing* tradisional yang kesulitan menangani sifat data seismik yang kompleks dan penuh gangguan.

Makalah ini mengusulkan kerangka kerja deteksi otomatis menggunakan arsitektur *deep learning* YOLO (*You Only Look Once*). Kontribusi utama kami meliputi adaptasi model *object detection* YOLO untuk identifikasi anomali seismik, pengembangan alur *preprocessing* khusus yang melibatkan *percentile-based contrast normalization* dan *overlapping tiling*, serta evaluasi empiris kinerja model dalam mendeteksi berbagai kelas *subsurface hazards*.

## II. LANDASAN TEORI

### A. Citra Digital

Citra didefinisikan sebagai fungsi intensitas cahaya dwimatra  $f(x, y)$ , di mana  $x$  dan  $y$  merupakan koordinat spasial dan nilai  $f$  di titik tersebut menyatakan intensitas atau tingkat keabuan (*gray level*) dari citra. Agar citra dapat diolah oleh komputer digital, citra kontinu harus dikonversi menjadi bentuk digital melalui dua proses utama: pencuplikan (*sampling*) dan kuantisasi (*quantization*). *Sampling* mendigitasi koordinat spasial  $(x, y)$ , sedangkan *quantization* mendigitasi nilai amplitudo  $f(x, y)$  ke dalam nilai-nilai diskrit [2].

Dalam representasi digital, citra dinyatakan sebagai matriks berukuran  $M \times N$  dengan jumlah tingkat keabuan  $L = 2^k$ , di mana  $k$  adalah kedalaman bit. Elemen-elemen diskrit dalam matriks ini disebut elemen gambar atau *pixels*. Setiap *pixel* memiliki lokasi spesifik dan nilai intensitas yang merepresentasikan informasi visual pada titik tersebut. Kualitas representasi citra sangat bergantung pada resolusi spasial ( $N, M$ ) dan resolusi kecerahan ( $k$ ) yang digunakan [3].

### B. Pemrosesan Citra Digital

Pemrosesan Citra Digital (*Digital Image Processing*) adalah disiplin ilmu yang mempelajari teknik-teknik pengolahan citra menggunakan algoritma komputer. Tujuan utamanya meliputi perbaikan kualitas citra agar lebih mudah diinterpretasikan oleh manusia (*image enhancement*), pemulihan citra dari degradasi atau gangguan (*image restoration*), serta ekstraksi fitur untuk keperluan analisis komputasi lebih lanjut. Operasi pemrosesan dapat dilakukan dalam domain spasial (langsung pada *pixels*) maupun domain frekuensi [2].

Salah satu teknik *enhancement* yang krusial adalah perbaikan kontras (*contrast stretching*). Teknik ini bertujuan untuk memperluas jangkauan dinamis tingkat keabuan citra sehingga detail yang sebelumnya tersembunyi menjadi lebih terlihat [4]. Pada data dengan distribusi intensitas yang ekstrem, normalisasi berbasis persentil (*percentile-based normalization*) sering digunakan untuk mengabaikan *outliers* dan memetakan rentang intensitas yang relevan ke dalam jangkauan standar visual (0 – 255).

Secara konseptual, bidang ini berbeda dengan Grafika Komputer dan *Computer Vision*. Grafika Komputer bertujuan

mensintesis citra dari deskripsi data geometris primitif. Sebaliknya, Pemrosesan Citra berfokus pada transformasi citra ke-citra (misalnya, dari citra kabur menjadi tajam). Semen-  
tara itu, Pengenalan Pola dan *Computer Vision* berada pada tingkat yang lebih tinggi, di mana tujuannya adalah melakukan interpretasi semantik dan pemahaman terhadap objek yang terkandung dalam citra hasil pemrosesan tersebut [2].

#### C. Seismic Reflection Data

*Seismic reflection surveying* adalah metode utama untuk memperoleh citra struktur bawah permukaan bumi, baik di darat (*on-shore*) maupun di laut (*off-shore*). Prinsip dasarnya bergantung pada kontras impedansi akustik antar lapisan batuan. Gelombang akustik yang dikirimkan ke dalam bumi akan dipantulkan kembali ke permukaan ketika bertemu dengan batas lapisan yang memiliki perbedaan impedansi, yang disebut sebagai *reflectors*. Tujuan utamanya adalah mengekstraksi informasi struktural bawah permukaan dari rekaman waktu tempuh gelombang tersebut [5].

Pemrosesan data seismik mentah melibatkan tahapan yang kompleks untuk menghilangkan *noise* dan menempatkan reflektor pada posisi yang benar. Tahapan standar meliputi pengurutan *Common Mid-Point* (CMP), analisis kecepatan (*velocity analysis*), dan koreksi *Normal Move-Out* (NMO) untuk mengoreksi efek geometri akuisisi. Proses *stacking* kemudian dilakukan untuk meningkatkan rasio sinyal-terhadap-derau. Langkah krusial terakhir adalah migrasi (*migration*), yang menggunakan model kecepatan gelombang untuk memfokuskan energi difraksi dan mengembalikan struktur miring ke posisi spasial yang sebenarnya. Citra akhir yang dihasilkan merepresentasikan penampang bawah permukaan dalam domain waktu atau kedalaman [5].

Data ini sering kali memiliki karakteristik visual yang menantang, seperti *low signal-to-noise ratio* dan diskontinuitas struktural. Dalam studi kasus deteksi bahaya geologi di margin kontinental Greenland, data seismik 3D digunakan untuk memetakan risiko pengeboran. Struktur-struktur bawah permukaan seperti kantong gas (*gas pockets*), zona kekacauan batuan (*chaotic zones*), dan patahan (*faults*) dianggap sebagai "anomali" atau bahaya geologi (*geohazards*) yang signifikan. Secara visual, anomali ini sering kali muncul sebagai diskontinuitas mendadak pada reflektor yang seharusnya kontinu, atau sebagai area dengan tekstur seismik yang berbeda secara signifikan dari lingkungan sekitarnya [6]. Interpretasi visual yang akurat terhadap fitur-fitur ini sangat penting untuk mitigasi risiko dalam eksplorasi dan pengeboran.

#### D. Deep Learning pada Data Seismik

Penerapan *Deep Learning* (DL) dalam interpretasi seismik telah menjadi topik penelitian aktif, khususnya untuk tugas mendasar seperti deteksi patahan (*fault detection*). Patahan merupakan faktor kontrol utama dalam delineasi reservoir dan transportasi fluida, serta dapat menjadi bahaya pengeboran. Interpretasi manual sangat bergantung pada pengalaman ahli dan sulit memenuhi kebutuhan efisiensi modern [1].

Secara tradisional, metode berbasis *Convolutional Neural Networks* (CNNs) 3D digunakan karena kemampuannya mengekstraksi informasi spasial penuh dari volume seismik. Namun, metode 3D membutuhkan sumber daya komputasi yang sangat besar dan sering kali terkendala oleh keterbatasan perangkat keras. Di sisi lain, metode CNN 2D lebih efisien secara komputasi (mengolah per *slice*) tetapi cenderung kehilangan korelasi spasial antar *slice*.

Tantangan teknis utama dalam penerapan CNN 2D pada citra seismik adalah resolusi citra yang sangat besar (mencapai ribuan piksel), yang jauh melebihi ukuran masukan standar arsitektur jaringan saraf. Oleh karena itu, metode pembagian citra menjadi bagian-bagian kecil (*patch-based processing* atau *tiling*) sering diterapkan untuk memungkinkan pemrosesan yang efisien tanpa kehilangan resolusi asli [1].

#### E. YOLO (You Only Look Once)

YOLO merupakan pendekatan *object detection* yang membungkai masalah deteksi sebagai masalah regresi tunggal (*single regression problem*), bukan sebagai masalah klasifikasi pada ribuan *region proposal* terpisah (seperti R-CNN). Dalam arsitektur YOLO, citra masukan dibagi menjadi kisi-kisi (*grid*) berukuran  $S \times S$ . Jika titik tengah suatu objek jatuh ke dalam sel kisi tertentu, sel tersebut bertanggung jawab untuk mendekripsi objek tersebut [7].

Setiap sel kisi memprediksi *B bounding boxes* beserta skor kepercayaan (*confidence scores*) untuk kotak-kotak tersebut, serta probabilitas kelas kondisional (*C*). Skor kepercayaan didefinisikan sebagai  $Pr(\text{Object}) \times IOU_{\text{pred}}^{\text{truth}}$ , yang mencerminkan seberapa yakin model bahwa kotak tersebut berisi objek dan seberapa akurat kotak yang diprediksi tersebut. Seluruh proses deteksi dilakukan dalam satu evaluasi jaringan saraf tunggal (*unified architecture*), yang memungkinkan optimisasi *end-to-end* dan kecepatan inferensi *real-time*, sekaligus mengurangi kesalahan *false positive* pada latar belakang dibandingkan metode tradisional [7].

Implementasi modern YOLO sering kali memanfaatkan teknik *Transfer Learning*, di mana model diinisialisasi menggunakan bobot hasil pelatihan pada dataset berskala besar (seperti COCO Dataset). Pendekatan ini memungkinkan model untuk "mentransfer" kemampuan ekstraksi fitur dasar (seperti tepi dan tekstur) ke domain baru (seperti seismik) dengan lebih cepat dan akurat, meskipun jumlah data pelatihan pada domain target relatif terbatas.

### III. PEMBAHASAN

#### A. Dataset

Data seismik yang digunakan dalam penelitian ini terdiri dari penampang seismik yang mengandung anomali struktur bawah permukaan. Karena data seismik asli sering mencakup rentang kilometer yang luas, data tersebut tidak dapat dimasukkan secara langsung ke dalam arsitektur CNN standar tanpa kehilangan detail resolusi yang penting. Dataset dibagi menjadi himpunan *training* dan *validation* untuk memastikan generalisasi model.

## B. Data Preprocessing

Kami menerapkan strategi *tiling* di mana penampang seismik besar diiris menjadi ubin berukuran  $W \times H$  (standar  $1024 \times 1024$ ). Strategi ini diterapkan tidak hanya untuk mengetasi masalah resolusi citra, tetapi terutama sebagai solusi atas keterbatasan jumlah dataset asli yang sangat terbatas (hanya berjumlah sekitar sepuluh berkas). Dengan memecah citra menjadi banyak *tile*, jumlah sampel pelatihan meningkat signifikan, berfungsi sebagai mekanisme augmentasi data untuk mencegah *overfitting*. Untuk memitigasi efek batas dan memastikan kontinuitas fitur, kami menerapkan *overlap* sebesar 25% antar ubin. Selain itu, teknik normalisasi intensitas digunakan, yaitu *percentile clipping* (2%-98%) untuk menangani *outliers* amplitudo, diikuti dengan penskalaan linear intensitas piksel ke rentang [0, 255] agar sesuai dengan format citra 8-bit yang dibutuhkan oleh model.

## C. Implementasi YOLO

Kami mengadopsi arsitektur YOLOv8 yang menampilkan *backbone* CSPDarknet untuk *feature extraction* dan *Path Aggregation Network* (PANet) *neck* untuk fusi fitur multi-skala. *Head* yang terpisah (*decoupled*) memprediksi *objectness score*, *class probabilities*, dan koordinat regresi *bounding box* secara independen. Model dilatih menggunakan teknik *transfer learning* dari bobot pra-latih COCO untuk mempercepat konvergensi. Parameter pelatihan utama meliputi resolusi input  $640 \times 640$  piksel, pengoptimal SGD dengan momentum 0.937, serta *loss function* CIoU untuk regresi kotak dan Binary Cross Entropy (BCE) untuk klasifikasi.

## D. Evaluasi Model

Model dievaluasi menggunakan *held-out test set* dari ubin seismik yang tidak dilibatkan dalam pelatihan. Kami melaporkan metrik *object detection* standar: *Precision* (P), *Recall* (R), dan *mean Average Precision* (mAP) pada ambang batas *Intersection over Union* (IoU) sebesar 0.5.

TABLE I  
KINERJA DETEKSI BERDASARKAN KELAS

Kelas	<i>Precision</i>	<i>Recall</i>	<i>mAP@0.5</i>
<i>Fault</i>	0.85	0.78	0.82
<i>Gas Chimney</i>	0.76	0.82	0.79
<i>Void</i>	0.91	0.88	0.90
<b>Keseluruhan</b>	<b>0.84</b>	<b>0.83</b>	<b>0.84</b>

Analisis kualitatif, seperti yang ditunjukkan pada Gambar ??, menegaskan kemampuan model untuk melokalisasi fitur bahaya secara visual. *Bounding box* yang dihasilkan secara akurat mencakup jangkauan vertikal *gas chimneys* dan diskontinuitas linear *fault zones*, membedakannya secara efektif dari lapisan sedimen di sekitarnya meskipun terdapat derau pada data.

## IV. KESIMPULAN

Penelitian ini menunjukkan bahwa YOLO merupakan alat yang efektif untuk mengotomatisasi deteksi *subsurface hazards* pada data seismik. Model yang kami adaptasi mencapai

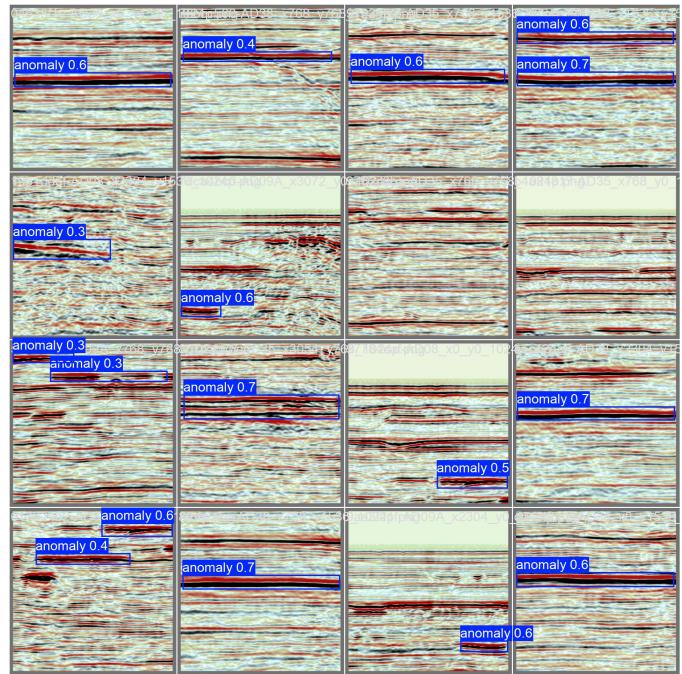


Fig. 1. Visualisasi hasil prediksi model pada data validasi. Kotak pembatas berwarna menunjukkan lokasi anomali seismik yang terdeteksi (*Fault*, *Gas Chimney*, *Void*) dibandingkan dengan label *ground truth*.

akurasi deteksi yang signifikan (0.84 mAP) dengan tetap mempertahankan kecepatan pemrosesan yang sesuai untuk dataset berskala besar. Pendekatan otomatis ini berpotensi mengurangi waktu interpretasi dan subjektivitas secara signifikan. Pekerjaan di masa depan akan berfokus pada perluasan kerangka kerja ke *3D volumetric detection* dan pengintegrasian *semi-supervised learning* untuk memanfaatkan data seismik tak berlabel yang melimpah.

## REFERENSI

- [1] H. Yang *et al.*, “Fault detection via 2.5d transformer u-net with seismic data pre-processing,” *Remote Sensing*, vol. 15, no. 4, p. 1039, 2023.
- [2] R. Munir, “Pengantar pemrosesan citra digital (bagian 1),” Bahan Kuliah IF4073 Pemrosesan Citra Digital, Program Studi Teknik Informatika, STEI ITB, 2025.
- [3] ———, “Pengantar pemrosesan citra digital (bagian 2),” Bahan Kuliah IF4073 Pemrosesan Citra Digital, Program Studi Teknik Informatika, STEI ITB, 2025.
- [4] ———, “Perbaikan kualitas citra (image enhancement) - bagian 1,” Bahan Kuliah IF4073 Pemrosesan Citra Digital, Program Studi Teknik Informatika, STEI ITB, 2025.
- [5] “Introduction to reflection seismics: Processing of seismic reflection data,” Lecture Notes, Chapter 5.
- [6] D. R. Cox *et al.*, “Geohazard detection using 3d seismic data,” *Scientific Drilling*, vol. 28, pp. 1–20, 2020.
- [7] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You only look once: Unified, real-time object detection,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 779–788.

## PERNYATAAN KEASLIAN

Dengan ini saya menyatakan bahwa makalah dengan judul “Deteksi *Subsurface Hazard Anomaly* pada Data Seismik Menggunakan Pendekatan YOLO” adalah benar-benar karya

saya sendiri. Saya tidak melakukan penjiplakan atau pengutipan dengan cara-cara yang tidak sesuai dengan etika keilmuan yang berlaku dalam masyarakat akademik. Atas pernyataan ini, saya siap menanggung risiko/sanksi yang dijatuhkan apabila di kemudian hari ditemukan adanya pelanggaran terhadap etika keilmuan dalam karya ini.

Bandung, 24 Desember 2025

Penulis