

Deteksi *Subsurface Hazard Anomaly* pada Data Seismik Menggunakan Pendekatan YOLO

Ahmad Naufal Ramadan - 13522005

Program Studi Teknik Informatika

Sekolah Teknik Elektro dan Informatika

Institut Teknologi Bandung

Jl. Ganesha 10 Bandung 40132, Indonesia

13522005@std.stei.itb.ac.id, naufalahmad022@gmail.com

Abstrak—Makalah ini menyajikan pendekatan *deep learning* untuk identifikasi otomatis *subsurface geological hazards* pada citra seismik menggunakan kerangka kerja *object detection* You Only Look Once (YOLO). *Seismic interpretation* secara tradisional merupakan proses manual yang memakan waktu dan bersifat subjektif. Kami mendemonstrasikan bahwa YOLO dapat melokalisasi anomali seperti *fault zones*, *gas chimneys*, dan *subsurface voids* dengan cepat dan akurat. Metodologi kami melibatkan alur *preprocessing* yang ketat, termasuk *percentile-based contrast normalization* dan *overlapping tiling* untuk menangani penampang seismik berskala besar. Hasil eksperimen menunjukkan bahwa model mencapai akurasi yang signifikan dalam mendeteksi pola berbahaya, menawarkan alat yang menjanjikan untuk membantu ahli geofisika dalam survei awal dan *risk assessment*.

Kata Kunci—*Seismic Interpretation, Subsurface Hazards, Object Detection, YOLO, Deep Learning, Geophysics, Digital Image Processing*

I. PENDAHULUAN

Seismic interpretation merupakan langkah fundamental dalam eksplorasi hidrokarbon dan penilaian *subsurface hazard*. Proses ini melibatkan analisis data refleksi seismik untuk mengidentifikasi struktur geologi seperti *faults*, *horizons*, dan *gas chimneys* [1]. Secara tradisional, proses ini dilakukan secara manual oleh interpreter berpengalaman, yang memakan waktu dan bersifat subjektif, sehingga berpotensi menimbulkan inkonsistensi dalam penilaian risiko.

Seiring dengan pertumbuhan volume data seismik yang eksponensial, interpretasi manual menjadi hambatan utama (*bottleneck*). Selain itu, fitur bahaya yang halus seperti *small fault zones* atau *gas pockets* dapat dengan mudah terlewatkan dalam data yang *noisy*, yang menimbulkan risiko signifikan bagi operasi pengeboran. Metode otomatis yang ada sering kali bergantung pada teknik *image processing* tradisional yang kesulitan menangani sifat data seismik yang kompleks dan penuh gangguan.

Makalah ini mengusulkan kerangka kerja deteksi otomatis menggunakan arsitektur *deep learning* YOLO (*You Only Look Once*). Kontribusi utama kami meliputi adaptasi model *object detection* YOLO untuk identifikasi anomali seismik, pengembangan alur *preprocessing* khusus yang melibatkan *percentile-based contrast normalization* dan *overlapping tiling*, serta evaluasi empiris kinerja model dalam mendeteksi berbagai kelas *subsurface hazards*.

Kegagalan dalam mendeteksi bahaya bawah permukaan ini dapat berakibat fatal, mulai dari kerugian finansial akibat *dry holes* hingga risiko keselamatan operasional seperti *shallow gas blowouts* [2]. Oleh karena itu, pengembangan alat bantu deteksi otomatis yang cepat dan andal bukan hanya masalah efisiensi, tetapi juga masalah keselamatan dan mitigasi risiko. Pendekatan berbasis data ini diharapkan dapat melengkapi (bukan menggantikan) keahlian interpreter manusia dengan menyediakan "opini kedua" yang objektif dan konsisten.

Sistematika penulisan makalah ini disusun sebagai berikut: Bagian II memaparkan landasan teori terkait citra seismik dan arsitektur YOLO. Bagian III menjelaskan metodologi penelitian, mulai dari persiapan dataset hingga konfigurasi pelatihan. Bagian IV menyajikan analisis hasil eksperimen, baik secara kuantitatif maupun kualitatif. Terakhir, Bagian V memberikan kesimpulan dan saran untuk pengembangan masa depan.

II. LANDASAN TEORI

A. Citra Digital

Citra didefinisikan sebagai fungsi intensitas cahaya dwimatra $f(x, y)$, di mana x dan y merupakan koordinat spasial dan nilai f di titik tersebut menyatakan intensitas atau tingkat keabuan (*gray level*) dari citra. Agar citra dapat diolah oleh komputer digital, citra kontinu harus dikonversi menjadi bentuk digital melalui dua proses utama: pencuplikan (*sampling*) dan kuantisasi (*quantization*). *Sampling* mendigitasi koordinat spasial (x, y) , sedangkan *quantization* mendigitasi nilai amplitudo $f(x, y)$ ke dalam nilai-nilai diskrit [3].

Dalam representasi digital, citra dinyatakan sebagai matriks berukuran $M \times N$ dengan jumlah tingkat keabuan $L = 2^k$, di mana k adalah kedalaman bit. Elemen-elemen diskrit dalam matriks ini disebut elemen gambar atau *pixels*. Setiap *pixel* memiliki lokasi spesifik dan nilai intensitas yang merepresentasikan informasi visual pada titik tersebut. Kualitas representasi citra sangat bergantung pada resolusi spasial (N, M) dan resolusi kecerahan (k) yang digunakan [4].

B. Pemrosesan Citra Digital

Pemrosesan Citra Digital (*Digital Image Processing*) adalah disiplin ilmu yang mempelajari teknik-teknik pengolahan citra menggunakan algoritma komputer. Tujuan utamanya meliputi

perbaikan kualitas citra agar lebih mudah diinterpretasikan oleh manusia (*image enhancement*), pemulihan citra dari degradasi atau gangguan (*image restoration*), serta ekstraksi fitur untuk keperluan analisis komputasi lebih lanjut. Operasi pemrosesan dapat dilakukan dalam domain spasial (langsung pada *pixels*) maupun domain frekuensi [3].

Salah satu teknik *enhancement* yang krusial adalah perbaikan kontras (*contrast stretching*). Teknik ini bertujuan untuk memperluas jangkauan dinamis tingkat keabuan citra sehingga detail yang sebelumnya tersembunyi menjadi lebih terlihat [5]. Pada data dengan distribusi intensitas yang ekstrem, normalisasi berbasis persentil (*percentile-based normalization*) sering digunakan untuk mengabaikan *outliers* dan memetakan rentang intensitas yang relevan ke dalam jangkauan standar visual (0 – 255).

Secara konseptual, bidang ini berbeda dengan Grafika Komputer dan *Computer Vision*. Grafika Komputer bertujuan mensintesis citra dari deskripsi data geometris primitif. Sebaliknya, Pemrosesan Citra berfokus pada transformasi citra-ke-citra (misalnya, dari citra kabur menjadi tajam). Sementara itu, Pengenalan Pola dan *Computer Vision* berada pada tingkat yang lebih tinggi, di mana tujuannya adalah melakukan interpretasi semantik dan pemahaman terhadap objek yang terkandung dalam citra hasil pemrosesan tersebut [3].

C. Seismic Reflection Data

Seismic reflection surveying adalah metode utama untuk memperoleh citra struktur bawah permukaan bumi, baik di darat (*on-shore*) maupun di laut (*off-shore*). Prinsip dasarnya bergantung pada kontras impedansi akustik antar lapisan batuan. Gelombang akustik yang dikirimkan ke dalam bumi akan dipantulkan kembali ke permukaan ketika bertemu dengan batas lapisan yang memiliki perbedaan impedansi, yang disebut sebagai *reflectors*. Tujuan utamanya adalah mengekstraksi informasi struktural bawah permukaan dari rekaman waktu tempuh gelombang tersebut [6].

Pemrosesan data seismik mentah melibatkan tahapan yang kompleks untuk menghilangkan *noise* dan menempatkan reflektor pada posisi yang benar. Tahapan standar meliputi pengurutan *Common Mid-Point* (CMP), analisis kecepatan (*velocity analysis*), dan koreksi *Normal Move-Out* (NMO) untuk mengoreksi efek geometri akuisisi. Proses *stacking* kemudian dilakukan untuk meningkatkan rasio sinyal-terhadap-derau. Langkah krusial terakhir adalah migrasi (*migration*), yang menggunakan model kecepatan gelombang untuk memfokuskan energi difraksi dan mengembalikan struktur miring ke posisi spasial yang sebenarnya. Citra akhir yang dihasilkan merepresentasikan penampang bawah permukaan dalam domain waktu atau kedalaman [6].

Data ini sering kali memiliki karakteristik visual yang menantang, seperti *low signal-to-noise ratio* dan diskontinuitas struktural. Dalam studi kasus deteksi bahaya geologi di margin kontinental Greenland, data seismik 3D digunakan untuk memetakan risiko pengeboran. Struktur-struktur bawah permukaan seperti kantong gas (*gas pockets*), zona kekacauan batuan (*chaotic zones*), dan patahan (*faults*) dianggap sebagai

”anomali” atau bahaya geologi (*geohazards*) yang signifikan. Secara visual, anomali ini sering kali muncul sebagai diskontinuitas mendadak pada reflektor yang seharusnya kontinu, atau sebagai area dengan tekstur seismik yang berbeda secara signifikan dari lingkungan sekitarnya [7]. Interpretasi visual yang akurat terhadap fitur-fitur ini sangat penting untuk mitigasi risiko dalam eksplorasi dan pengeboran.

D. Deep Learning pada Data Seismik

Penerapan *Deep Learning* (DL) dalam interpretasi seismik telah menjadi topik penelitian aktif, khususnya untuk tugas mendasar seperti deteksi patahan (*fault detection*). Patahan merupakan faktor kontrol utama dalam delineasi reservoir dan transportasi fluida, serta dapat menjadi bahaya pengeboran. Interpretasi manual sangat bergantung pada pengalaman ahli dan sulit memenuhi kebutuhan efisiensi modern [1].

Secara tradisional, metode berbasis *Convolutional Neural Networks* (CNNs) 3D digunakan karena kemampuannya mengekstraksi informasi spasial penuh dari volume seismik. Namun, metode 3D membutuhkan sumber daya komputasi yang sangat besar dan sering kali terkendala oleh keterbatasan perangkat keras. Di sisi lain, metode CNN 2D lebih efisien secara komputasi (mengolah per *slice*) tetapi cenderung kehilangan korelasi spasial antar *slice*.

Tantangan teknis utama dalam penerapan CNN 2D pada citra seismik adalah resolusi citra yang sangat besar (mencapai ribuan piksel), yang jauh melebihi ukuran masukan standar arsitektur jaringan saraf. Oleh karena itu, metode pembagian citra menjadi bagian-bagian kecil (*patch-based processing* atau *tiling*) sering diterapkan untuk memungkinkan pemrosesan yang efisien tanpa kehilangan resolusi asli [1].

E. YOLO (You Only Look Once)

YOLO merupakan pendekatan *object detection* yang membongkai masalah deteksi sebagai masalah regresi tunggal (*single regression problem*), bukan sebagai masalah klasifikasi pada ribuan *region proposal* terpisah (seperti R-CNN). Dalam arsitektur YOLO, citra masukan dibagi menjadi kisi-kisi (*grid*) berukuran $S \times S$. Jika titik tengah suatu objek jatuh ke dalam sel kisi tertentu, sel tersebut bertanggung jawab untuk mendeteksi objek tersebut [8].

Setiap sel kisi memprediksi B *bounding boxes* beserta skor kepercayaan (*confidence scores*) untuk kotak-kotak tersebut, serta probabilitas kelas kondisional (C). Skor kepercayaan didefinisikan sebagai $Pr(Object) \times IOU_{pred}^{truth}$, yang mencerminkan seberapa yakin model bahwa kotak tersebut berisi objek dan seberapa akurat kotak yang diprediksi tersebut. Seluruh proses deteksi dilakukan dalam satu evaluasi jaringan saraf tunggal (*unified architecture*), yang memungkinkan optimalisasi *end-to-end* dan kecepatan inferensi *real-time*, sekaligus mengurangi kesalahan *false positive* pada latar belakang dibandingkan metode tradisional [8].

Implementasi modern YOLO sering kali memanfaatkan teknik *Transfer Learning*, di mana model diinisialisasi menggunakan bobot hasil pelatihan pada dataset berskala besar (seperti COCO Dataset). Pendekatan ini memungkinkan model

untuk "mentransfer" kemampuan ekstraksi fitur dasar (seperti tepi dan tekstur) ke domain baru (seperti seismik) dengan lebih cepat dan akurat, meskipun jumlah data pelatihan pada domain target relatif terbatas.

F. Metrik Evaluasi Deteksi Objek

Evaluasi kinerja model deteksi objek menggunakan metrik standar yang berbeda dengan klasifikasi citra biasa [9], [10]. Metrik utama yang digunakan meliputi *Intersection over Union* (IoU), *Precision*, *Recall*, dan *Mean Average Precision* (mAP).

1) *Intersection over Union* (IoU): IoU mengukur tumpang tindih antara kotak prediksi (B_p) dan kotak *ground truth* (B_{gt}). Nilai IoU didefinisikan sebagai rasio luas irisan terhadap luas gabungan kedua kotak tersebut:

$$IoU = \frac{Area(B_p \cap B_{gt})}{Area(B_p \cup B_{gt})} \quad (1)$$

Nilai IoU berkisar antara 0 hingga 1. Sebuah prediksi dianggap benar (*True Positive*) jika nilai IoU-nya melebihi ambang batas tertentu (biasanya 0.5).

2) *Precision dan Recall*: *Precision* mengukur seberapa akurat deteksi positif yang dilakukan oleh model, sedangkan *Recall* mengukur seberapa baik model menemukan seluruh objek positif yang ada dalam dataset.

$$Precision = \frac{TP}{TP + FP} \quad (2)$$

$$Recall = \frac{TP}{TP + FN} \quad (3)$$

Dimana TP adalah *True Positive*, FP adalah *False Positive*, dan FN adalah *False Negative*.

3) *Mean Average Precision* (mAP): mAP adalah rata-rata dari *Average Precision* (AP) untuk setiap kelas. AP sendiri dihitung dengan mencari luas daerah di bawah kurva *Precision-Recall*. Metrik mAP@0.5 menghitung mAP dengan ambang batas IoU sebesar 0.5, sedangkan mAP@0.5:0.95 menghitung rata-rata mAP pada berbagai ambang batas IoU (dari 0.5 hingga 0.95 dengan interval 0.05). Metrik ini memberikan gambaran performa model yang lebih komprehensif, mencakup akurasi lokasi dan klasifikasi.

III. METODOLOGI

A. Dataset

Dataset yang digunakan dalam penelitian ini merupakan data seismik riil yang diperoleh dari perusahaan minyak dan gas bumi (*oil and gas*) yang beroperasi di kawasan Asia Tenggara. Dikarenakan sifat kerahasiaan (*confidential*) data industri, detail lokasi dan atribut geofisika spesifik tidak dapat dipublikasikan secara terbuka. Dataset awal terdiri dari 13 citra penampang seismik yang merepresentasikan struktur bawah permukaan. Setelah melalui proses *tiling* dan *filtering*, diperoleh total 74 sampel ubin (*tiles*) yang layak digunakan. Dataset ini kemudian dibagi menjadi himpunan pelatihan (*training set*) sebanyak 49 sampel dan himpunan validasi (*validation set*) sebanyak 25 sampel. Terbatasnya jumlah data asli ini menjadi

tantangan utama yang diatasi melalui strategi *preprocessing* dan pembagian ubin yang sistematis.

B. Data Preprocessing

Tahap pra-pemrosesan data memegang peranan krusial untuk mengubah data seismik mentah menjadi format yang sesuai untuk pelatihan model *deep learning*. Implementasi lengkap proses ini dirancang dalam modul `preprocessing/seismic_tiler.py`¹. Langkah-langkah utamanya adalah sebagai berikut:

- 1) **Konversi dan Normalisasi**: Citra seismik dikonversi menjadi format *grayscale*. Untuk meningkatkan kontras fitur anomali, diterapkan teknik *percentile clipping* (default 1%-99%). Misalkan $I(x, y)$ adalah intensitas piksel awal, dan p_{low}, p_{high} adalah nilai intensitas pada persentil ke-1 dan ke-99. Proses *clipping* didefinisikan sebagai:

$$I_{clip}(x, y) = \min(\max(I(x, y), p_{low}), p_{high}) \quad (4)$$

Selanjutnya, dilakukan normalisasi *min-max* ke rentang $[0, 255]$:

$$I_{norm}(x, y) = \frac{I_{clip}(x, y) - p_{low}}{p_{high} - p_{low}} \times 255 \quad (5)$$

Teknik ini memastikan fitur penting tidak hilang akibat *outliers* yang ekstrem.

- 2) **Tiling dengan Overlap**: Mengingat dimensi penampang seismik yang sangat besar ($W \times H$), citra dipecah menjadi ubin-ubin (*tiles*) berukuran $T \times T$ (default 1024×1024). Untuk menjaga kontinuitas fitur geologi, diterapkan strategi *overlapping* dengan rasio r (default 0.25). Langkah pergeseran/stride (S) dihitung sebagai:

$$S = \lfloor T \times (1 - r) \rfloor \quad (6)$$

Koordinat pojok kiri atas (x_i, y_j) untuk setiap ubin ditentukan oleh $x_i = i \times S$ dan $y_j = j \times S$, dengan penanganan khusus pada batas tepi citra untuk memastikan seluruh area tercakup.

- 3) **Filtering**: Ubin yang tidak mengandung informasi signifikan (misalnya area kosong atau *minimum information*) disaring secara otomatis menggunakan ambang batas standar deviasi tertentu (σ_{thresh}). Jika $\sigma_{tile} < \sigma_{thresh}$, ubin tersebut dibuang dari dataset pelatihan untuk mencegah model belajar dari data kosong.

Potongan kode berikut memperlihatkan implementasi logika iterasi *tiling* (Gambar 1):

Setelah proses *tiling*, dilakukan pelabelan manual (*annotation*) menggunakan perangkat lunak **Label Studio**. Area yang diidentifikasi sebagai anomali pada setiap ubin ditandai dengan *bounding box*. Hasil pelabelan ini kemudian diekspor dan diunduh dalam bentuk arsip `data.zip` yang berisi direktori citra dan label dalam format standar YOLO untuk pelatihan.

¹Kode sumber lengkap (preprocessing dan training) tersedia di: <https://github.com/SandWithCheese/makalah-citra>

```
def iterate_tiles(W, H, tile, overlap):
    stride = max(1, int(tile * (1.0 - overlap)))
    y = 0
    while y < H:
        x = 0
        while x < W:
            # Calculate coordinates
            x1 = min(x + tile, W)
            y1 = min(y + tile, H)
            x0 = max(0, x1 - tile)
            y0 = max(0, y1 - tile)
            yield x0, y0, x1 - x0, y1 - y0
            # ... update x ...
        # ... update y ...

model = YOLO('yolo11s.pt')
results = model.train(
    data=data_yaml,
    epochs=60,
    imgsz=640,
    batch=16,
    device=device
)
```

Gambar 1. Potongan kode implementasi strategi tiling.

C. Implementasi YOLO

Pelatihan model deteksi objek dilakukan menggunakan skrip `src/train_yolo.py` yang dibangun di atas kerangka kerja Ultralytics. Model yang dipilih untuk eksperimen ini adalah `yolo11s.pt` (YOLOv11 Small). Varian ini menawarkan keseimbangan optimal antara biaya komputasi dan akurasi deteksi, yang sangat sesuai untuk eksperimen awal pada perangkat keras terbatas. *Hardware* dan *software* yang digunakan untuk eksperimen ini dirangkum dalam Tabel I.

Tabel I
SPESIFIKASI LINGKUNGAN EKSPERIMEN

Komponen	Spesifikasi
CPU	Intel Core i7-12700H
GPU	NVIDIA GeForce RTX 3060 Laptop GPU (6GB)
RAM	16 GB DDR5
OS	Ubuntu 22.04 LTS (WSL2)
Python	Versi 3.10
PyTorch	Versi 2.1.0+cu121
Ultralytics	Versi 8.1.0

Alur kerja pelatihan mencakup langkah-langkah otomatis berikut:

- 1) Ekstraksi dataset dari `data.zip`.
- 2) Pembagian dataset menjadi himpunan *train* (90%) dan *validation* (10%) secara acak untuk memastikan evaluasi yang objektif.
- 3) Pembuatan berkas konfigurasi `data.yaml` secara dinamis sesuai struktur folder yang terbentuk.
- 4) Pelatihan model (*fine-tuning*) menggunakan bobot awal (*pretrained weights*) untuk mempercepat konvergensi.

Kode implementasi utama untuk inisiasi pelatihan adalah sebagai berikut (Gambar 2):

IV. HASIL DAN PEMBAHASAN

Evaluasi kinerja model dilakukan secara komprehensif menggunakan metrik deteksi objek standar, analisis kurva performansi, dan validasi visual terhadap data validasi (*held-out validation set*).

Gambar 2. Konfigurasi pelatihan model YOLO.


1) *Ringkasan Metrik Utama*: Model menunjukkan kemampuan lokalisasi objek yang sangat presisi, ditandai dengan nilai *mean Average Precision* (mAP) yang tinggi. Tabel II merangkum metrik performansi utama yang dicapai model.

Tabel II
RINGKASAN METRIK PERFORMANSI UTAMA

Metrik	Nilai	Keterangan
mAP@0.5	0.962 (96,2%)	Indikasi presisi tinggi
Max F1-Score	0.89	Pada <i>confidence</i> 0.164
Max Precision	1.00	Pada <i>confidence</i> 0.362
Max Recall	1.00	Pada <i>confidence</i> 0.000

2) *Analisis Confusion Matrix*: Analisis terhadap *Confusion Matrix* (Gambar 3) memperlihatkan akurasi prediksi model terhadap label *ground truth*:

- **True Positive (TP)**: Model berhasil mendeteksi 24 anomali dengan benar.
- **False Negative (FN)**: Terdapat 10 anomali aktual yang terlewat oleh model, menghasilkan tingkat keberhasilan deteksi (*Recall*) efektif sebesar 71%.
- **False Positive (FP)**: Hanya 1 sampel latar belakang (*background*) yang salah diklasifikasikan sebagai anomali, menunjukkan tingkat kesalahan alarm palsu yang sangat rendah.




Gambar 3. Confusion Matrix hasil evaluasi pada data validasi.

3) *Analisis Kurva dan Titik Optimal*: Kurva *Precision-Recall* (PR) yang ditunjukkan pada Gambar 5 membentuk pola siku yang mendekati sudut kanan atas, menegaskan stabilitas model dengan mAP mencapai 0.962 pada ambang batas IoU 0.5.


Penentuan ambang batas (*threshold*) kepercayaan menjadi krusial untuk implementasi:

- 1) **Keseimbangan Optimal:** Nilai F1-Score tertinggi dicapai pada ambang batas **0.164** (Gambar 4). Ini adalah titik rekomendasi operasional untuk menyeimbangkan antara presisi dan sensitivitas.



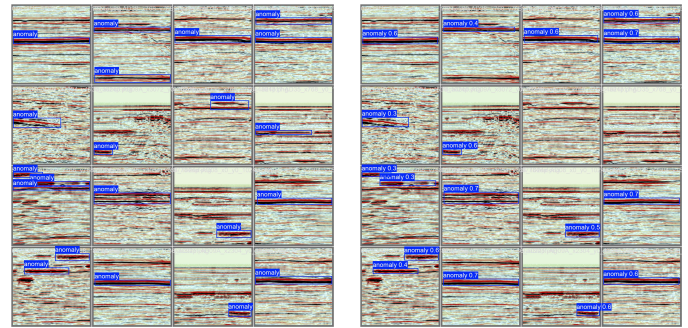
Gambar 4. Kurva F1-Confidence menunjukkan keseimbangan optimal antara Presisi dan Recall pada threshold tertentu.

- 2) **Keandalan Tinggi:** Jika prioritas adalah meniadakan alarm palsu (*zero false alarm*), ambang batas dapat dinaikkan ke **0.362**, di mana presisi mencapai nilai sempurna 1.00.



Gambar 5. Kurva Precision-Recall (PR) menunjukkan area di bawah kurva yang luas, merepresentasikan mAP yang tinggi.


- 4) **Validasi Visual dan Analisis Kegagalan:** Validasi kualitatif dilakukan dengan membandingkan prediksi model terhadap citra label asli. Secara umum, model mampu mendeteksi fitur anomali yang memiliki kontras tinggi dengan baik (Gambar 6).



Gambar 6. Perbandingan visual (a) Label anomali asli dan (b) Hasil deteksi model. Kotak pembatas pada (b) menunjukkan prediksi dengan skor kepercayaan terkait.

Namun, analisis lebih mendalam terhadap kasus *False Negatives* (Gambar 7) mengungkapkan beberapa faktor utama penyebab kegagalan deteksi:

- 1) **Rasio Sinyal-terhadap-Noise (SNR) Rendah:** Anomali dengan intensitas sinyal yang lemah sering kali tersamarkan oleh *noise* seismik latar belakang, membuatnya sulit dibedakan oleh model dibandingkan anomali yang kontras.
- 2) **Ambiguitas Fitur:** Beberapa struktur geologi seperti lapisan batuan yang kacau (*chaotic layering*) memiliki kemiripan visual dengan pola anomali gas atau retakan, menyebabkan model ragu (skor kepercayaan rendah) untuk memberikan label positif.
- 3) **Efek Batas Ubin:** Meskipun strategi *overlap* telah diterapkan, anomali yang terpotong di tepi ubin terkadang kehilangan konteks spasial yang cukup untuk diidentifikasi dengan yakin.



Gambar 7. Analisis False Negatives: Visualisasi anomali yang gagal dideteksi (kotak merah). Kegagalan umumnya terjadi pada fitur yang samar atau memiliki karakteristik visual yang sangat mirip dengan tekstur latar belakang.

5) *Diskusi Kesenjangan Metrik: Recall vs mAP*: Terdapat perbedaan yang tampak signifikan antara nilai mAP@0.5 yang sangat tinggi (0.962) dengan nilai Recall efektif yang lebih rendah (71-85% bergantung pada *threshold*). Kesenjangan ini dapat dijelaskan sebagai berikut:

- **Interpretasi mAP**: Nilai mAP yang tinggi menunjukkan bahwa model sebenarnya berhasil mengidentifikasi dan memprioritaskan (*ranking*) anomali dengan benar dibandingkan area latar belakang. Model "mengetahui" keberadaan objek tersebut.
- **Isu Kepercayaan (Confidence)**: Rendahnya Recall pada ambang batas standar disebabkan oleh banyaknya deteksi benar yang memiliki skor kepercayaan rendah (misalnya 0.2 – 0.4). Model mendeteksi pola tersebut, namun kurang "yakini" karena ambiguitas visual pada data seismik.

Oleh karena itu, untuk aplikasi praktis yang mengutamakan keselamatan (*safety-critical*), disarankan untuk menurunkan ambang batas deteksi (*confidence threshold*) ke level 0.16–0.20. Langkah ini akan secara efektif memulihkan anomali yang sebelumnya dianggap "terlewat" (False Negatives), dengan konsekuensi sedikit peningkatan pada False Positives yang dapat diverifikasi lebih lanjut oleh interpreter manusia.

V. KESIMPULAN

Berdasarkan hasil eksperimen dan analisis yang telah dilakukan, dapat disimpulkan bahwa implementasi metode *You Only Look Once* (YOLO) efektif dalam mendeteksi anomali bahaya bawah permukaan (*subsurface hazards*) pada citra seismik. Model berhasil mencapai kinerja deteksi yang sangat presisi dengan nilai *mean Average Precision* (mAP@0.5) sebesar 0.962. Evaluasi pada *confusion matrix* menunjukkan kemampuan model yang kuat dalam meminimalisir kesalahan deteksi palsu (*false positives*), dengan hanya ditemukan satu kesalahan identifikasi latar belakang sebagai anomali pada data validasi.

Meskipun presisi yang dihasilkan sangat tinggi, model masih memiliki keterbatasan dalam mengenali anomali dengan kontras rendah atau fitur visual yang samar, sebagaimana ditunjukkan oleh adanya sejumlah kasus *False Negative*. Berdasarkan analisis kurva F1, pengaturan ambang batas kepercayaan (*confidence threshold*) pada nilai 0.164 direkomendasikan sebagai titik operasional optimal. Pada titik ini, model mencapai keseimbangan terbaik antara sensitivitas dan presisi dengan skor F1 maksimal sebesar 0.89, yang cukup memadai untuk fungsi penapisan awal dalam alur kerja interpretasi seismik.

Untuk pengembangan penelitian selanjutnya, disarankan untuk memperluas dataset pelatihan dengan variasi augmentasi kontras yang lebih agresif guna meningkatkan sensitivitas model terhadap anomali yang samar. Selain itu, transisi menuju pendekatan deteksi volumetrik 3D perlu dipertimbangkan untuk memanfaatkan informasi kontinuitas spasial antar-slice yang tidak tertangkap pada analisis 2D. Eksplorasi teknik *semi-supervised learning* juga berpotensi meningkatkan generalisasi model dengan memanfaatkan ketersediaan data

seismik tak berlabel yang melimpah. Penelitian ini menegaskan potensi besar pendekatan berbasis visi komputer sebagai alat bantu interpretasi geofisika, namun hasil deteksi tetap memerlukan validasi ahli untuk pengambilan keputusan eksplorasi.

REFERENSI

- [1] H. Yang *et al.*, "Fault detection via 2.5d transformer u-net with seismic data pre-processing," *Remote Sensing*, vol. 15, no. 4, p. 1039, 2023.
- [2] S. Nissen, W. Watney, and J. Xia, "High-resolution seismic detection of shallow natural gas beneath hutchinson, kansas," *Environmental Geosciences*, vol. 11, pp. 129–142, 09 2004.
- [3] R. Munir, "Pengantar pemrosesan citra digital (bagian 1)," Bahan Kuliah IF4073 Pemrosesan Citra Digital, Program Studi Teknik Informatika, STEI ITB, 2025.
- [4] —, "Pengantar pemrosesan citra digital (bagian 2)," Bahan Kuliah IF4073 Pemrosesan Citra Digital, Program Studi Teknik Informatika, STEI ITB, 2025.
- [5] —, "Perbaikan kualitas citra (image enhancement) - bagian 1," Bahan Kuliah IF4073 Pemrosesan Citra Digital, Program Studi Teknik Informatika, STEI ITB, 2025.
- [6] TU Delft OpenCourseWare, "Introduction to reflection seismics: Processing of seismic reflection data," Lecture Notes, Chapter 5, diakses online. [Online]. Available: https://ocw.tudelft.nl/wp-content/uploads/Intro_reflection_seismics_Chapter_5_Processing_of_Seismic_Reflection_Data.pdf
- [7] D. R. Cox *et al.*, "Geohazard detection using 3d seismic data," *Scientific Drilling*, vol. 28, pp. 1–20, 2020.
- [8] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You only look once: Unified, real-time object detection," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 779–788.
- [9] P. Henderson and V. Ferrari, "End-to-end training of object class detectors for mean average precision," *arXiv preprint arXiv:1607.03476*, 2016.
- [10] H. Rezatofighi, N. Tsoi, J. Gwak, A. Sadeghian, I. Reid, and S. Savarese, "Generalized intersection over union: A metric and a loss for bounding box regression," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2019, pp. 658–666.

PERNYATAAN KEASLIAN

Dengan ini saya menyatakan bahwa makalah yang saya tulis ini adalah tulisan saya sendiri, bukan saduran, atau terjemahan dari makalah orang lain, dan bukan plagiasi.

Bandung, 24 Desember 2025



Ahmad Naufal Ramadan - 13522005