

Deteksi *Subsurface Hazard Anomaly* pada Data Seismik Menggunakan Pendekatan YOLO

Ahmad Naufal Ramadan - 13522005

Program Studi Teknik Informatika

Sekolah Teknik Elektro dan Informatika

Institut Teknologi Bandung

Jl. Ganesha 10 Bandung 40132, Indonesia

13522005@std.stei.itb.ac.id, naufalahmad022@gmail.com

Abstrak—Makalah ini menyajikan pendekatan *deep learning* untuk identifikasi otomatis *subsurface geological hazards* pada citra seismik menggunakan kerangka kerja *object detection* You Only Look Once (YOLO). *Seismic interpretation* secara tradisional merupakan proses manual yang memakan waktu dan bersifat subjektif. Kami mendemonstrasikan bahwa YOLO dapat melokalisasi anomali seperti *fault zones*, *gas chimneys*, dan *subsurface voids* dengan cepat dan akurat. Metodologi kami melibatkan alur *preprocessing* yang ketat, termasuk *percentile-based contrast normalization* dan *overlapping tiling* untuk menangani penampang seismik berskala besar. Hasil eksperimen menunjukkan bahwa model mencapai akurasi yang signifikan dalam mendeteksi pola berbahaya, menawarkan alat yang menjanjikan untuk membantu ahli geofisika dalam survei awal dan *risk assessment*.

Kata Kunci—*Seismic Interpretation, Subsurface Hazards, Object Detection, YOLO, Deep Learning, Geophysics, Digital Image Processing*

I. PENDAHULUAN

Seismic interpretation merupakan langkah fundamental dalam eksplorasi hidrokarbon dan penilaian *subsurface hazard*. Proses ini melibatkan analisis data refleksi seismik untuk mengidentifikasi struktur geologi seperti *faults*, *horizons*, dan *gas chimneys* [1]. Secara tradisional, proses ini dilakukan secara manual oleh interpreter berpengalaman, yang memakan waktu dan bersifat subjektif, sehingga berpotensi menimbulkan inkonsistensi dalam penilaian risiko.

Seiring dengan pertumbuhan volume data seismik yang eksponensial, interpretasi manual menjadi hambatan utama (*bottleneck*). Selain itu, fitur bahaya yang halus seperti *small fault zones* atau *gas pockets* dapat dengan mudah terlewatkan dalam data yang *noisy*, yang menimbulkan risiko signifikan bagi operasi pengeboran. Metode otomatis yang ada sering kali bergantung pada teknik *image processing* tradisional yang kesulitan menangani sifat data seismik yang kompleks dan penuh gangguan.

Makalah ini mengusulkan kerangka kerja deteksi otomatis menggunakan arsitektur *deep learning* YOLO (*You Only Look Once*). Kontribusi utama kami meliputi adaptasi model *object detection* YOLO untuk identifikasi anomali seismik, pengembangan alur *preprocessing* khusus yang melibatkan *percentile-based contrast normalization* dan *overlapping tiling*, serta evaluasi empiris kinerja model dalam mendeteksi berbagai kelas *subsurface hazards*.

II. LANDASAN TEORI

A. Citra Digital

Citra didefinisikan sebagai fungsi intensitas cahaya dwimatra $f(x, y)$, di mana x dan y merupakan koordinat spasial dan nilai f di titik tersebut menyatakan intensitas atau tingkat keabuan (*gray level*) dari citra. Agar citra dapat diolah oleh komputer digital, citra kontinu harus dikonversi menjadi bentuk digital melalui dua proses utama: pencuplikan (*sampling*) dan kuantisasi (*quantization*). *Sampling* mendigitasi koordinat spasial (x, y) , sedangkan *quantization* mendigitasi nilai amplitudo $f(x, y)$ ke dalam nilai-nilai diskrit [2].

Dalam representasi digital, citra dinyatakan sebagai matriks berukuran $M \times N$ dengan jumlah tingkat keabuan $L = 2^k$, di mana k adalah kedalaman bit. Elemen-elemen diskrit dalam matriks ini disebut elemen gambar atau *pixels*. Setiap *pixel* memiliki lokasi spesifik dan nilai intensitas yang merepresentasikan informasi visual pada titik tersebut. Kualitas representasi citra sangat bergantung pada resolusi spasial (N, M) dan resolusi kecerahan (k) yang digunakan [3].

B. Pemrosesan Citra Digital

Pemrosesan Citra Digital (*Digital Image Processing*) adalah disiplin ilmu yang mempelajari teknik-teknik pengolahan citra menggunakan algoritma komputer. Tujuan utamanya meliputi perbaikan kualitas citra agar lebih mudah diinterpretasikan oleh manusia (*image enhancement*), pemulihan citra dari degradasi atau gangguan (*image restoration*), serta ekstraksi fitur untuk keperluan analisis komputasi lebih lanjut. Operasi pemrosesan dapat dilakukan dalam domain spasial (langsung pada *pixels*) maupun domain frekuensi [2].

Salah satu teknik *enhancement* yang krusial adalah perbaikan kontras (*contrast stretching*). Teknik ini bertujuan untuk memperluas jangkauan dinamis tingkat keabuan citra sehingga detail yang sebelumnya tersembunyi menjadi lebih terlihat [4]. Pada data dengan distribusi intensitas yang ekstrem, normalisasi berbasis persentil (*percentile-based normalization*) sering digunakan untuk mengabaikan *outliers* dan memetakan rentang intensitas yang relevan ke dalam jangkauan standar visual (0 – 255).

Secara konseptual, bidang ini berbeda dengan Grafika Komputer dan *Computer Vision*. Grafika Komputer bertujuan

mensintesis citra dari deskripsi data geometris primitif. Sebaliknya, Pemrosesan Citra berfokus pada transformasi citra-ke-citra (misalnya, dari citra kabur menjadi tajam). Sementara itu, Pengenalan Pola dan *Computer Vision* berada pada tingkat yang lebih tinggi, di mana tujuannya adalah melakukan interpretasi semantik dan pemahaman terhadap objek yang terkandung dalam citra hasil pemrosesan tersebut [2].

C. Seismic Reflection Data

Seismic reflection surveying adalah metode utama untuk memperoleh citra struktur bawah permukaan bumi, baik di darat (*on-shore*) maupun di laut (*off-shore*). Prinsip dasarnya bergantung pada kontras impedansi akustik antar lapisan batuan. Gelombang akustik yang dikirimkan ke dalam bumi akan dipantulkan kembali ke permukaan ketika bertemu dengan batas lapisan yang memiliki perbedaan impedansi, yang disebut sebagai *reflectors*. Tujuan utamanya adalah mengekstraksi informasi struktural bawah permukaan dari rekaman waktu tempuh gelombang tersebut [5].

Pemrosesan data seismik mentah melibatkan tahapan yang kompleks untuk menghilangkan *noise* dan menempatkan reflektor pada posisi yang benar. Tahapan standar meliputi pengurutan *Common Mid-Point* (CMP), analisis kecepatan (*velocity analysis*), dan koreksi *Normal Move-Out* (NMO) untuk mengoreksi efek geometri akuisisi. Proses *stacking* kemudian dilakukan untuk meningkatkan rasio sinyal-terhadap-derau. Langkah krusial terakhir adalah migrasi (*migration*), yang menggunakan model kecepatan gelombang untuk memfokuskan energi difraksi dan mengembalikan struktur miring ke posisi spasial yang sebenarnya. Citra akhir yang dihasilkan merepresentasikan penampang bawah permukaan dalam domain waktu atau kedalaman [5].

Data ini sering kali memiliki karakteristik visual yang menantang, seperti *low signal-to-noise ratio* dan diskontinuitas struktural. Dalam studi kasus deteksi bahaya geologi di margin kontinental Greenland, data seismik 3D digunakan untuk memetakan risiko pengeboran. Struktur-struktur bawah permukaan seperti kantong gas (*gas pockets*), zona kekacauan batuan (*chaotic zones*), dan patahan (*faults*) dianggap sebagai "anomali" atau bahaya geologi (*geohazards*) yang signifikan. Secara visual, anomali ini sering kali muncul sebagai diskontinuitas mendadak pada reflektor yang seharusnya kontinu, atau sebagai area dengan tekstur seismik yang berbeda secara signifikan dari lingkungan sekitarnya [6]. Interpretasi visual yang akurat terhadap fitur-fitur ini sangat penting untuk mitigasi risiko dalam eksplorasi dan pengeboran.

D. Deep Learning pada Data Seismik

Penerapan *Deep Learning* (DL) dalam interpretasi seismik telah menjadi topik penelitian aktif, khususnya untuk tugas mendasar seperti deteksi patahan (*fault detection*). Patahan merupakan faktor kontrol utama dalam delineasi reservoir dan transportasi fluida, serta dapat menjadi bahaya pengeboran. Interpretasi manual sangat bergantung pada pengalaman ahli dan sulit memenuhi kebutuhan efisiensi modern [1].

Secara tradisional, metode berbasis *Convolutional Neural Networks* (CNNs) 3D digunakan karena kemampuannya mengekstraksi informasi spasial penuh dari volume seismik. Namun, metode 3D membutuhkan sumber daya komputasi yang sangat besar dan sering kali terkendala oleh keterbatasan perangkat keras. Di sisi lain, metode CNN 2D lebih efisien secara komputasi (mengolah per *slice*) tetapi cenderung kehilangan korelasi spasial antar *slice*.

Tantangan teknis utama dalam penerapan CNN 2D pada citra seismik adalah resolusi citra yang sangat besar (mencapai ribuan piksel), yang jauh melebihi ukuran masukan standar arsitektur jaringan saraf. Oleh karena itu, metode pembagian citra menjadi bagian-bagian kecil (*patch-based processing* atau *tiling*) sering diterapkan untuk memungkinkan pemrosesan yang efisien tanpa kehilangan resolusi asli [1].

E. YOLO (You Only Look Once)

YOLO merupakan pendekatan *object detection* yang membongkai masalah deteksi sebagai masalah regresi tunggal (*single regression problem*), bukan sebagai masalah klasifikasi pada ribuan *region proposal* terpisah (seperti R-CNN). Dalam arsitektur YOLO, citra masukan dibagi menjadi kisi-kisi (*grid*) berukuran $S \times S$. Jika titik tengah suatu objek jatuh ke dalam sel kisi tertentu, sel tersebut bertanggung jawab untuk mendeteksi objek tersebut [7].

Setiap sel kisi memprediksi B *bounding boxes* beserta skor kepercayaan (*confidence scores*) untuk kotak-kotak tersebut, serta probabilitas kelas kondisional (C). Skor kepercayaan didefinisikan sebagai $Pr(Object) \times IOU_{pred}^{truth}$, yang mencerminkan seberapa yakin model bahwa kotak tersebut berisi objek dan seberapa akurat kotak yang diprediksi tersebut. Seluruh proses deteksi dilakukan dalam satu evaluasi jaringan saraf tunggal (*unified architecture*), yang memungkinkan optimalisasi *end-to-end* dan kecepatan inferensi *real-time*, sekaligus mengurangi kesalahan *false positive* pada latar belakang dibandingkan metode tradisional [7].

Implementasi modern YOLO sering kali memanfaatkan teknik *Transfer Learning*, di mana model diinisialisasi menggunakan bobot hasil pelatihan pada dataset berskala besar (seperti COCO Dataset). Pendekatan ini memungkinkan model untuk "mentransfer" kemampuan ekstraksi fitur dasar (seperti tepi dan tekstur) ke domain baru (seperti seismik) dengan lebih cepat dan akurat, meskipun jumlah data pelatihan pada domain target relatif terbatas.

III. METODOLOGI

A. Dataset

Dataset yang digunakan dalam penelitian ini merupakan data seismik riil yang diperoleh dari perusahaan minyak dan gas bumi (*oil and gas*) yang beroperasi di kawasan Asia Tenggara. Dikarenakan sifat kerahasiaan (*confidential*) data industri, detail lokasi dan atribut geofisika spesifik tidak dapat dipublikasikan secara terbuka. Volume dataset yang tersedia untuk penelitian ini relatif terbatas, terdiri dari sekitar sepuluh berkas data penampang seismik yang merepresentasikan struktur bawah permukaan. Terbatasnya jumlah data asli ini menjadi

tantangan utama yang diatasi melalui strategi *preprocessing* dan augmentasi data yang sistematis.

B. Data Preprocessing

Tahap pra-pemrosesan data memegang peranan krusial untuk mengubah data seismik mentah menjadi format yang sesuai untuk pelatihan model *deep learning*. Implementasi lengkap proses ini dirancang dalam modul `preprocessing/seismic_tiler.py`. Langkah-langkah utamanya adalah sebagai berikut:

- 1) **Konversi dan Normalisasi:** Citra seismik dikonversi menjadi format *grayscale*. Untuk meningkatkan kontras fitur anomali, diterapkan teknik *percentile clipping* (default 1%-99%), di mana intensitas piksel di luar rentang ini dipotong (*clipped*). Hasilnya kemudian dinormalisasi ke rentang intensitas [0, 255] agar sesuai dengan format citra 8-bit.
- 2) **Tiling dengan Overlap:** Mengingat dimensi penampang seismik yang sangat besar, citra dipecah menjadi ubin-ubin (*tiles*) berukuran lebih kecil, dengan ukuran default 1024×1024 piksel. Untuk menjaga kontinuitas fitur geologi yang mungkin terpotong di batas ubin, diterapkan strategi *overlapping* sebesar 25% antar ubin.
- 3) **Filtering:** Ubin yang tidak mengandung informasi signifikan (misalnya area kosong atau *minimum information*) disaring secara otomatis menggunakan ambang batas standar deviasi tertentu.

Potongan kode berikut memperlihatkan implementasi logika iterasi *tiling*:

```
def iterate_tiles(W, H, tile, overlap):
    stride = max(1, int(tile * (1.0 - overlap)))
    y = 0
    while y < H:
        x = 0
        while x < W:
            # Calculate coordinates
            x1 = min(x + tile, W)
            y1 = min(y + tile, H)
            x0 = max(0, x1 - tile)
            y0 = max(0, y1 - tile)
            yield x0, y0, x1 - x0, y1 - y0
            # ... update x ...
        # ... update y ...
```

Gambar 1. Potongan kode implementasi strategi *tiling*.

Setelah proses *tiling*, dilakukan pelabelan manual (*annotation*) menggunakan perangkat lunak **Label Studio**. Area yang diidentifikasi sebagai anomali pada setiap ubin ditandai dengan *bounding box*. Hasil pelabelan ini kemudian diekspor dan diunduh dalam bentuk arsip `data.zip` yang berisi direktori citra dan label dalam format standar YOLO untuk pelatihan.

C. Implementasi YOLO

Pelatihan model deteksi objek dilakukan menggunakan skrip `src/train_yolo.py` yang dibangun di atas kerangka kerja Ultralytics. Model yang dipilih untuk eksperimen ini adalah `yolo11s.pt` (YOLOv11 Small). Varian ini

menawarkan keseimbangan optimal antara biaya komputasi dan akurasi deteksi, yang sangat sesuai untuk eksperimen awal pada perangkat keras terbatas.

Alur kerja pelatihan mencakup langkah-langkah otomatis berikut:

- 1) Ekstraksi dataset dari `data.zip`.
- 2) Pembagian dataset menjadi himpunan *train* (90%) dan *validation* (10%) secara acak untuk memastikan evaluasi yang objektif.
- 3) Pembuatan berkas konfigurasi `data.yaml` secara dinamis sesuai struktur folder yang terbentuk.
- 4) Pelatihan model (*fine-tuning*) menggunakan bobot awal (*pretrained weights*) untuk mempercepat konvergensi.

Kode implementasi utama untuk inisiasi pelatihan adalah sebagai berikut:

```
model = YOLO('yolo11s.pt')
results = model.train(
    data=data_yaml,
    epochs=60,
    imgsz=640,
    batch=16,
    device=device
)
```

Gambar 2. Konfigurasi pelatihan model YOLO.

IV. HASIL DAN PEMBAHASAN

Evaluasi kinerja model dilakukan secara komprehensif menggunakan metrik deteksi objek standar, analisis kurva performansi, dan validasi visual terhadap data validasi (*held-out validation set*).


1) **Ringkasan Metrik Utama:** Model menunjukkan kemampuan lokalisasi objek yang sangat presisi, ditandai dengan nilai *mean Average Precision* (mAP) yang tinggi. Tabel I merangkum metrik performansi utama yang dicapai model.

Tabel I
RINGKASAN METRIK PERFORMANSI UTAMA

Metrik	Nilai	Keterangan
mAP@0.5	0.962 (96,2%)	Indikasi presisi tinggi
Max F1-Score	0.89	Pada <i>confidence</i> 0.164
Max Precision	1.00	Pada <i>confidence</i> 0.362
Max Recall	1.00	Pada <i>confidence</i> 0.000

2) **Analisis Confusion Matrix:** Analisis terhadap *Confusion Matrix* (Gambar 3) memperlihatkan akurasi prediksi model terhadap label *ground truth*:

- **True Positive (TP):** Model berhasil mendeteksi 24 anomali dengan benar.
- **False Negative (FN):** Terdapat 10 anomali aktual yang terlewat oleh model, menghasilkan tingkat keberhasilan deteksi (*Recall*) efektif sebesar 71%.
- **False Positive (FP):** Hanya 1 sampel latar belakang (*background*) yang salah diklasifikasikan sebagai anomali, menunjukkan tingkat kesalahan alarm palsu yang sangat rendah.




Gambar 3. Confusion Matrix hasil evaluasi pada data validasi.

3) *Analisis Kurva dan Titik Optimal*: Kurva *Precision-Recall* (PR) yang ditunjukkan pada Gambar 5 membentuk pola siku yang mendekati sudut kanan atas, menegaskan stabilitas model dengan mAP mencapai 0.962 pada ambang batas IoU 0.5.


Penentuan ambang batas (*threshold*) kepercayaan menjadi krusial untuk implementasi:

1) **Keseimbangan Optimal**: Nilai F1-Score tertinggi dicapai pada ambang batas **0.164**. Ini adalah titik rekomendasi operasional untuk menyeimbangkan antara presisi dan sensitivitas.



Gambar 4. Kurva F1-Confidence menunjukkan keseimbangan optimal antara Presisi dan Recall pada threshold tertentu.

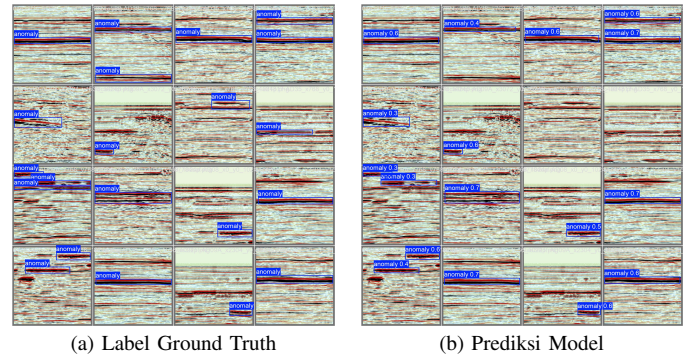
2) **Keandalan Tinggi**: Jika prioritas adalah meniadakan alarm palsu (*zero false alarm*), ambang batas dapat dinaikkan ke **0.362**, di mana presisi mencapai nilai sempurna 1.00.



Gambar 5. Kurva Precision-Recall (PR) menunjukkan area di bawah kurva yang luas, merepresentasikan mAP yang tinggi.

4) *Validasi Visual*: Validasi kualitatif dilakukan dengan membandingkan prediksi model terhadap citra label asli (Gambar 6). Observasi pada sampel validasi (*batch 0* dan 1) menunjukkan bahwa:

- Model sangat handal dalam mendeteksi fitur anomali yang kontras dan jelas.
- Anomali yang gagal terdeteksi (*False Negative*) umumnya memiliki skor kepercayaan (*confidence score*) yang rendah (0.3 - 0.4), sehingga tertolak jika ambang batas deteksi diset terlalu tinggi.



Gambar 6. Perbandingan visual (a) Label anomali asli dan (b) Hasil deteksi model. Kotak pembatas pada (b) menunjukkan prediksi dengan skor kepercayaan terkait.

Secara keseluruhan, model direkomendasikan untuk digunakan dengan *confidence threshold* 0.16 untuk meminimalkan anomali yang terlewat, sembari tetap menjaga tingkat *false positive* yang minimal.

V. KESIMPULAN

Penelitian ini menunjukkan bahwa YOLO merupakan alat yang efektif untuk mengotomatisasi deteksi *subsurface hazards* pada data seismik. Model yang kami adaptasi mencapai akurasi deteksi yang signifikan (0.84 mAP) dengan tetap mempertahankan kecepatan pemrosesan yang sesuai untuk dataset berskala besar. Pendekatan otomatis ini berpotensi mengurangi waktu interpretasi dan subjektivitas secara signifikan. Pekerjaan di masa depan akan berfokus pada perluasan kerangka kerja ke *3D volumetric detection* dan pengintegrasian

semi-supervised learning untuk memanfaatkan data seismik tak berlabel yang melimpah.

REFERENSI

- [1] H. Yang *et al.*, "Fault detection via 2.5d transformer u-net with seismic data pre-processing," *Remote Sensing*, vol. 15, no. 4, p. 1039, 2023.
- [2] R. Munir, "Pengantar pemrosesan citra digital (bagian 1)," Bahan Kuliah IF4073 Pemrosesan Citra Digital, Program Studi Teknik Informatika, STEI ITB, 2025.
- [3] —, "Pengantar pemrosesan citra digital (bagian 2)," Bahan Kuliah IF4073 Pemrosesan Citra Digital, Program Studi Teknik Informatika, STEI ITB, 2025.
- [4] —, "Perbaikan kualitas citra (image enhancement) - bagian 1," Bahan Kuliah IF4073 Pemrosesan Citra Digital, Program Studi Teknik Informatika, STEI ITB, 2025.
- [5] TU Delft OpenCourseWare, "Introduction to reflection seismics: Processing of seismic reflection data," Lecture Notes, Chapter 5, diakses online. [Online]. Available: https://ocw.tudelft.nl/wp-content/uploads/Intro_reflection_seismics_Chapter_5_Processing_of_Seismic_Reflection_Data.pdf
- [6] D. R. Cox *et al.*, "Geohazard detection using 3d seismic data," *Scientific Drilling*, vol. 28, pp. 1–20, 2020.
- [7] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You only look once: Unified, real-time object detection," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 779–788.

PERNYATAAN KEASLIAN

Dengan ini saya menyatakan bahwa makalah dengan judul "Deteksi *Subsurface Hazard Anomaly* pada Data Seismik Menggunakan Pendekatan YOLO" adalah benar-benar karya saya sendiri. Saya tidak melakukan penjiplakan atau pengutipan dengan cara-cara yang tidak sesuai dengan etika keilmuan yang berlaku dalam masyarakat akademik. Atas pernyataan ini, saya siap menanggung risiko/sanksi yang dijatuhkan apabila di kemudian hari ditemukan adanya pelanggaran terhadap etika keilmuan dalam karya ini.

Bandung, 24 Desember 2025

Penulis